

HEAL-GNN: INTELIGÊNCIA EM GRAFOS PARA MITIGAÇÃO DA EVASÃO ESCOLAR

2022004289 - Filipe Cruz Siqueira

CMAC03 - ALGORITMOS EM GRAFOS
Prof. Rafael Frinhani



INSTITUTO DE
MATEMÁTICA E
COMPUTAÇÃO

UNIFEI - Itajubá



HEAL-GNN: Inteligência em grafos para mitigação da evasão escolar

1 Introdução

1.1 Contextualização e Motivação

A evasão acadêmica no ensino superior representa um desafio complexo e persistente para as instituições de ensino, governos e para a sociedade em geral. O abandono prematuro dos estudos implica em significativas perdas financeiras para as universidades e desperdício de recursos públicos, bem como perpetua desigualdades sociais e frustra o desenvolvimento humano e profissional dos estudantes, sendo assim imprescindível a implementação de políticas que combatam as causas do problema.

Ao buscar por tais causas, historicamente, as propostas têm se apoiado em análises estatísticas tradicionais ou em modelos preditivos lineares, os quais tratam as variáveis do estudante (como dados demográficos, situação socioeconômica e desempenho acadêmico inicial) de forma isolada ou puramente tabular.

No entanto, o ambiente universitário contemporâneo configura-se como um ecossistema complexo e interdependente. O sucesso ou o fracasso de um discente não é determinado por um único fator isolado, mas sim resultado de interações constantes entre diferentes elementos que compõem múltiplas dimensões. É possível classificar as causas da evasão em três dimensões principais: fatores socioeconômicos, fatores acadêmicos e fatores institucionais. Essas dimensões são interligadas por relações de causa e efeito, evidenciando que dificuldades financeiras podem gerar estresse, reduzir o desempenho acadêmico, aumentar a desmotivação e, consequentemente, elevar a probabilidade de evasão. Da mesma forma,

problemas institucionais podem intensificar dificuldades acadêmicas e socioeconômicas, formando um ciclo de retroalimentação que favorece o abandono do curso.

Para compreender verdadeiramente essa dinâmica, faz-se necessário superar a visão reducionista das planilhas estáticas e adotar abordagens metodológicas baseadas na Ciência de Redes Complexas e na Inteligência Artificial Geométrica.

1.2 O Estado da Arte e a Abordagem por Grafos

A literatura recente em Learning Analytics aponta para a superação dos modelos tradicionais por meio de estruturas de grafos. O framework Heterogeneous Interaction Network Analysis (HINA) demonstra a eficácia de modelar múltiplos tipos de entidades (estudantes, disciplinas, comportamentos) em redes heterogêneas para descobrir perfis vulneráveis a nível meso (comunidades).

Complementarmente, arquiteturas como as Redes de Atenção em Grafos Relacionais e Temporais (RT-GAT) provaram que incorporar a semântica das relações (arestas de condução, colaboração e feedback) e a evolução temporal das notas melhora drasticamente a precisão preditiva em sistemas baseados em competências.

Por fim, o estado da arte valida que a combinação dessas representações estruturais geradas por Redes Neurais em Grafos (GNN) com modelos de ensemble baseados em árvores (como XGBoost e LightGBM) mitiga problemas severos de desbalanceamento de dados em ambientes reais, oferecendo alta escalabilidade e poder inferencial.

Tabela 1: Mapeamento Comparativo: Variáveis do Dataset vs. Abordagem Estrutural no Grafo.

VARIÁVEIS (data.csv)	ORIGINAIS	REPRESENTAÇÃO NO GRAFO	SEMÂNTICA E PAPEL NO MODELO HEAL-GNN
Age at enrollment, Gender, Displaced, Scholarship holder, Qualifications (Pais).		Atributos internos do Nó de Estudante (S_i).	Constituem o vetor inicial de características (x_{s_i}) do discente, mapeando o perfil socioeconômico e demográfico básico.
Course		Nó de Contexto / Entidade Independente (C_j).	Permite conectar indiretamente estudantes matriculados na mesma graduação, estabelecendo redes de afinidade e homofilia acadêmica.
Debtor, Tuition fees up to date		Supernós de Status Financeiro (Fin_OK ou Fin_At_Risk).	Agrupam os estudantes de acordo com o nível de adimplência ou vulnerabilidade econômica, propagando estresse financeiro via rede.
Curricular units 1st sem (enrolled, evaluations, approved, grade).		Arestas de Condução (<i>Driving Edges</i>).	Mapeiam a resposta imediata do estudante ao ingressar na universidade, ligando seu perfil às primeiras métricas de desempenho.
Curricular units 2nd sem (enrolled, evaluations, approved, grade).		Arestas de Feedback Temporal (<i>Temporal Feedback</i>).	Capturam a taxa de evolução, estabilidade ou declínio das notas e aprovações do 1º para o 2º semestre, isolando a trajetória de risco.

1.3 Objetivos do Projeto

O objetivo principal deste projeto é conceber e modelar a solução computacional HEAL-GNN (Heterogeneous Educational Analytics and Learning Graph Neural Network), uma ferramenta preditiva e analítica de ponta a ponta projetada para diagnosticar, mapear e mitigar o risco de evasão acadêmica a partir do dataset institucional fornecido.

Para alcançar o objetivo macro, estabelecem-se os seguintes objetivos específicos:

- **Modelagem Estrutural:** Transformar os dados tabulares estáticos em um grafo multirrelacional heterogêneo que capture explicitamente as interações entre os perfis dos alunos, suas escolhas de curso e suas trajetórias financeiras.
- **Análise Temporal e Causal:** Implementar mecanismos de atenção para rastrear a evolução do rendimento acadêmico (unidades curriculares inscritas, avaliadas e aprovadas) entre o primeiro e o segundo semestre, isolando os padrões de declínio que precedem o abandono.
- **Identificação de Perfis de Risco:** Descobrir, via agrupamento latente na rede, comunidades de estudantes vulneráveis (ex: desengajamento silencioso ou estresse financeiro acumulado) para subsidiar tomadas de decisão.
- **Predição e Suporte à Decisão:** Estruturar um pipeline híbrido (GNN + XGBoost) capaz de emitir alertas antecipados e sugerir intervenções institucionais personalizadas e direcionadas à raiz do problema de cada discente.

Com esta abordagem, o projeto visa fornecer à gestão pedagógica não apenas uma porcentagem estatística de chance de evasão, mas um mapa explicativo das diferentes componentes da vida universitária que levam o estudante ao desfecho observado.

2 Referencial Teórico

O desenvolvimento do framework HEAL-GNN fundamenta-se teórica e metodologicamente no estado da arte da Inteligência Artificial aplicada à educação (Learning Analytics), com especial foco na Ciência de Redes Complexas e no Aprendizado de Máquina Geométrico. Esta seção analisa criticamente os três artigos fundamentais que inspiraram a arquitetura da solução proposta, detalhando como seus conceitos e achados

científicos se relacionam diretamente com o problema da evasão acadêmica modelado a partir do conjunto de dados utilizado.

2.1 O Framework HINA e a Análise Multinível de Redes Educacionais

A modelagem estrutural do HEAL-GNN adota os princípios do framework Heterogeneous Interaction Network Analysis (HINA), [Feng et al. \(2026\)](#). O estudo original introduz uma abordagem metodológica capaz de estruturar ambientes de aprendizagem distribuídos e complexos por meio de redes heterogêneas, as quais superam a visão tradicional e linear de causa e efeito ao analisar entidades distintas de forma simultânea.

A pesquisa proposta conecta-se ao HINA principalmente na exploração de dados no nível meso (comunidades latentes). Enquanto modelos estatísticos convencionais isolam variáveis como a situação financeira do aluno (Debtor) ou o tipo de curso (Course), o framework adaptado agrupa os estudantes de forma não-paramétrica em ecossistemas de afinidade estrutural.

Ao transpor a lógica do HINA para o dataset de evasão, o HEAL-GNN consegue descobrir perfis emergentes de risco, tais como o padrão de "vulnerabilidade socioeconômica correlacionada", em que a proximidade de nós com mensalidades atrasadas gera uma força de atração na rede que arrasta o estudante em direção ao desfecho de abandono (Dropout), permitindo que a instituição mapeie não apenas o indivíduo, mas o comportamento do subgrupo em que ele está inserido.

2.2 O Modelo RT-GAT e as Dependências Temporais e Relacionais

O segundo pilar da solução é a arquitetura Relational Temporal-Graph Attention Network (RT-GAT), [Yang et al. \(2026\)](#). Os autores demonstraram que as habilidades e os resultados acadêmicos evoluem ao longo de múltiplos estágios letivos e que as conexões entre indicadores possuem semânticas diferentes (definidas no artigo como arestas de condução, colaboração e feedback).

Essa estrutura é diretamente integrada à nossa pesquisa para solucionar o maior desafio do dataset preditivo: o fator temporal. O conjunto de dados fornecido possui uma divisão clara de desempenho entre as unidades curriculares do 1º e do 2º semestre (inscrições, aprovações, avaliações e notas).

O HEAL-GNN utiliza o mecanismo de atenção ciente de relações do RT-GAT para rastrear a dinâmica de transição de

Tabela 2: Mapeamento de Contribuições Teóricas dos Trabalhos Relacionados.

ARTIGO DE ORIGEM	CONCEITO-CHAVE EXTRAÍDO	FUNÇÃO ESPECÍFICA NO HEAL-GNN
Framework HINA (2026)	Análise de redes heterogêneas no nível meso (comunidades).	Agrupamento não-paramétrico de estudantes em subgrupos latentes de risco (ex: desengajamento silencioso).
Modelo RT-GAT (2026)	Redes de atenção baseadas em relações e dinâmica temporal.	Ponderação adaptativa da transição e declínio de notas do discente entre o 1º e o 2º semestre letivo.
GNN + Ensemble (2025)	Integração de embeddings estruturais com modelos baseados em árvores.	Extração de vetores densos via GNN para classificação robusta e escalável via XGBoost/LightGBM com SMOTE.

desempenho do aluno. Arestas de "Condução" mapeiam o impacto do histórico socioeconômico e da nota de admissão no primeiro semestre, enquanto as arestas de "Feedback Temporal" avaliam a taxa de declínio ou resiliência no segundo semestre.

A distribuição dos pesos de atenção da rede permite calcular o quanto a variação negativa entre as notas dos dois semestres pesa na decisão final de evasão, gerando uma capacidade de explicação causal inédita em modelos puramente tabulares.

2.3 Modelos Híbridos (GNN + Ensemble) e a Resolução do Desbalanceamento

Por fim, a estratégia de predição e classificação do desfecho acadêmico (Target) baseia-se no trabalho de [Hakkal & Lahcen \(2025\)](#). Os pesquisadores identificaram que, embora as Redes Neurais em Grafos (GNNs) sejam excepcionais na extração de características estruturais e relacionais complexas através de embeddings, elas podem falhar ao classificar desfechos em conjuntos de dados reais altamente desbalanceados. A solução proposta por eles — que combina o processamento de grafos com classificadores de ensemble baseados em árvores, como XGBoost e LightGBM — estabelece o alicerce para a camada preditiva do HEAL-GNN.

Na nossa pesquisa, o desbalanceamento de classes é um desafio iminente, dado que o número de alunos graduados (Graduate) ou matriculados (Enrolled) tende a ser estatisticamente superior ao número de evadidos (Dropout).

A incorporação da técnica sugerida por Hakkal e Ait Lahcen permite que o HEAL-GNN utilize a GNN exclusivamente para comprimir as complexas relações relacionais e temporais do estudante em vetores densos (embeddings). Na sequência, esses vetores são injetados em um classificador XGBoost blindado por técnicas de sobreamostragem (como o SMOTE).

Essa sinergia garante ao projeto o melhor de dois mundos: o alto poder explicativo e contextual da teoria de grafos aliado à robustez matemática, escalabilidade computacional e sensibilidade de Recall das árvores de decisão.

3 Desenvolvimento

Esta seção apresenta a arquitetura do ecossistema HEAL-GNN, detalhando desde a natureza do problema de evasão acadêmica até o processo de conversão dos dados tabulares em grafos e concebe o pipeline computacional híbrido de predição.

3.1 Detalhamento do Problema

O fenômeno da evasão escolar no ensino superior é resultado da interação de múltiplos fatores de natureza acadêmica, socioeconômica, institucional e individual, que se manifestam de maneira heterogênea entre os estudantes. Em razão dessa complexidade, abordagens estatísticas tradicionais, que tratam cada aluno como uma observação independente, frequentemente não conseguem capturar as relações de dependência existentes entre diferentes indivíduos, cursos e períodos letivos. Além disso, esses métodos apresentam limitações para identificar os efeitos indiretos e em cascata provocados pela combinação simultânea de diferentes variáveis explicativas,

reduzindo sua capacidade de representar adequadamente a dinâmica da evasão.

Neste projeto, a evasão não é modelada apenas como um problema convencional de classificação supervisionada, mas como um problema de classificação de nós em um grafo dinâmico e multirrelacional. Nessa representação, os estudantes, disciplinas, cursos e demais entidades acadêmicas são modelados como vértices de um grafo, enquanto suas diversas formas de interação são representadas por arestas pertencentes a diferentes tipos de relacionamento.

Matematicamente, o objetivo consiste em aprender uma função de mapeamento

$$[f : \mathcal{G} \rightarrow \mathcal{Y},]$$

em que (f) representa o modelo de aprendizado responsável por inferir o estado acadêmico de cada estudante a partir da estrutura do grafo. O domínio dessa função é definido pelo grafo heterogêneo

$$[\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathcal{R}),]$$

no qual $(\mathcal{V})$ corresponde ao conjunto de vértices (ou nós), representando as diferentes entidades presentes na base de dados, como estudantes, disciplinas, cursos e departamentos; $(\mathcal{E})$ representa o conjunto de arestas, responsáveis por descrever as conexões existentes entre essas entidades; e $(\mathcal{R})$ representa o conjunto dos tipos de relacionamento existentes no grafo, permitindo diferenciar, por exemplo, relações de matrícula, aprovação, vínculo curricular ou pertencimento institucional.

O contradomínio da função é dado pelo conjunto

$$[\mathcal{Y} \in \text{Dropout, Enrolled, Graduate},]$$

que corresponde às possíveis classes atribuídas ao estudante. Para cada nó correspondente a um estudante (S_i) , onde o índice (i) identifica unicamente cada aluno da base de dados, o modelo produz uma predição pertencente ao conjunto $(\mathcal{Y})$. A classe (Dropout) indica que o estudante evadiu o curso, (Enrolled) indica que permanece regularmente matriculado e (Graduate) representa a conclusão bem-sucedida do curso.

Um dos principais desafios dessa modelagem consiste em separar o ruído presente nas variáveis demográficas e socioeconômicas dos padrões efetivamente relevantes para a predição da evasão. Paralelamente, torna-se necessário capturar as dependências temporais existentes ao longo da trajetória acadêmica dos estudantes, especialmente durante a transição entre o primeiro e o segundo semestre letivo, período frequentemente identificado na literatura como crítico para a permanência no ensino superior. Pequenas reduções no número de unidades curriculares aprovadas, quando analisadas isoladamente, podem parecer pouco significativas; entretanto, quando consideradas conjuntamente com o histórico acadêmico e com a rede de relações representada no grafo, podem desencadear padrões latentes que aumentam significativamente a probabilidade de evasão. Dessa forma, a modelagem baseada em grafos busca explorar simultaneamente as características individuais dos estudantes, a estrutura de suas interações e sua evolução temporal, proporcionando uma representação mais fiel da natureza complexa do fenômeno da evasão.

3.2 Modelagem

A modelagem traduz a estrutura estática do arquivo data.csv para uma topologia de rede rica em semântica.

DIAGRAMA DE ESTADOS – CICLO DE VIDA DO ESTUDANTE

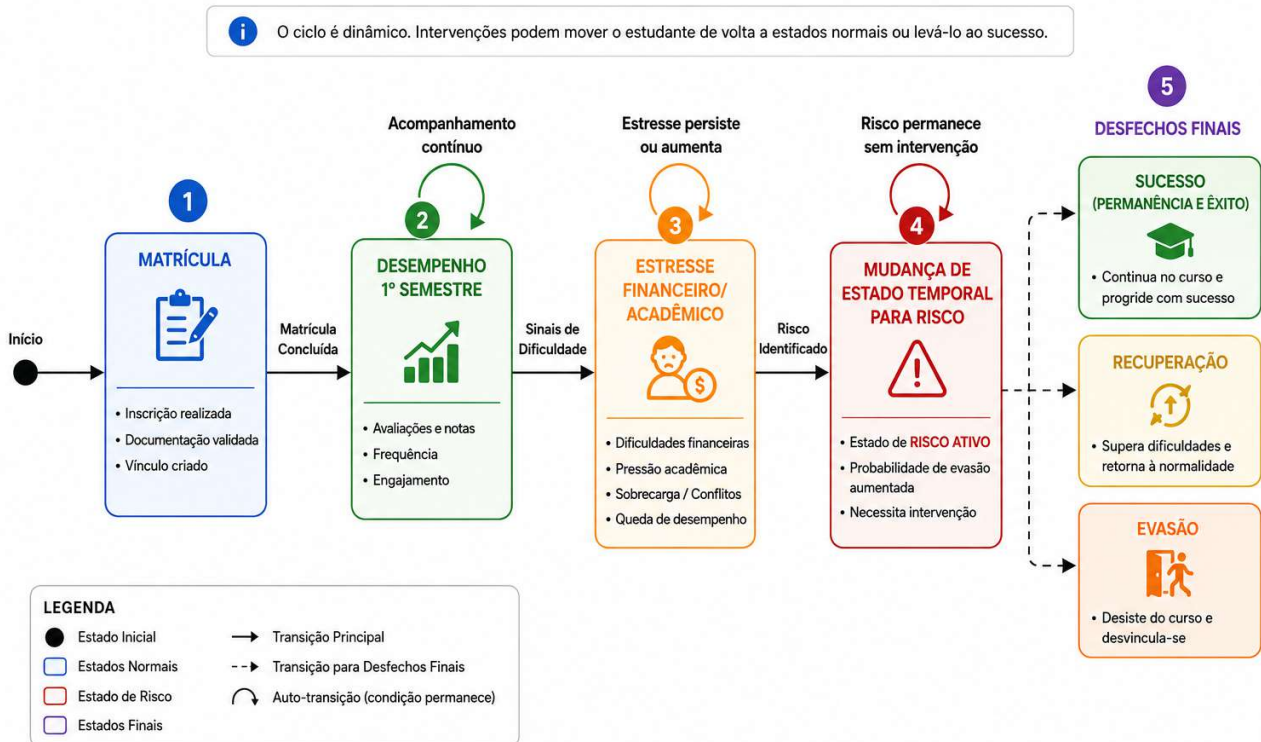


Figura 1: Fluxo de transição de estados do estudante.

3.2.1 Características do Dataset e Engenharia de Atributos

O conjunto de dados original é composto por registros individuais contendo fatores demográficos, socioeconômicos, dados de ingresso e indicadores de desempenho divididos em dois blocos semestrais. Para alimentar o grafo, as variáveis passam pelo seguinte processo de engenharia de atributos:

- **Atributos de Perfil (Internos ao Nó):** Variáveis como Age at enrollment, Gender, Scholarship holder e Displaced tornam-se o vetor de características iniciais do nó do estudante.
- **Entidades de Contexto (Nós de Apoio):** A variável Course é extraída da tabela para se tornar um nó contextual independente.
- **Variáveis de adimplência (Debtor e Tuition-fees-up-to-date):** São combinadas probabilisticamente para gerar supernós de Status Financeiro, segregando o ambiente em polos de estabilidade ou vulnerabilidade econômica.

3.2.2 Ilustração do Modelo em Grafo

A topologia gerada estabelece uma rede heterogênea bipartida e multiplex. Estudantes que compartilham o mesmo curso ou o mesmo status financeiro são conectados indiretamente através desses nós centrais, permitindo que algoritmos baseados

em grafos propaguem informações de comportamento de um nó para o outro (mecanismo de message passing).

Afim de possibilitar a visualização eficiente do grafo tomamos como amostra um conjunto de 150 alunos escolhidos aleatoriamente. Para fins de previsão efetiva do comportamento dos alunos, contudo, fazem-se necessários testes com grupos variados afim de obter estatísticas mais precisas.




Figura 2: Visualização da Topologia do Grafo HEAL-GNN.

3.3 Desenvolvimento

O desenvolvimento do framework computacional divide-se em duas camadas integradas: a extração de características espaciais via redes de atenção e a classificação robusta via ensemble learning.

Tabela 3: Dicionário Técnico de Nós, Arestas e Atributos Estruturais do HEAL-GNN.

COMPONENTE	TIPO / IDENTIFICADOR	COLUNAS ASSOCIADAS (data.csv) E ATRIBUTOS
Nó Central	Student (S_i)	<i>Atributos internos:</i> Marital status, Application mode, Application order, Previous qualification, Previous qualification (grade), Nationality, Mother's/Father's qualification, Mother's/Father's occupation, Admission grade, Educational special needs, Gender, International, Age at enrollment.
Nó Contextual	Course (C_j)	Coluna Course . Atua como pivô de agrupamento para identificar o comportamento de retenção por área de estudo.
Nó Contextual	FinancialStatus (F_k)	Colunas Debtor e Tuition fees up to date . Supernós categóricos que dividem a rede entre estabilidade ou risco financeiro.
Aresta Estrutural	<i>enrolled_in</i>	Estabelece o vínculo de matrícula direcionado entre o Nó de Estudante (S_i) e o Nó de Curso (C_j).
Aresta Estrutural	<i>has_status</i>	Conecta o Nó de Estudante (S_i) ao Nó FinancialStatus correspondente (<i>Fin_OK</i> ou <i>Fin_At_Risk</i>).
Aresta Dinâmica	<i>driving_edge</i> (1º sem)	<i>Pesos associados:</i> Curricular units 1st sem (credited, enrolled, evaluations, approved, grade, without evaluations).
Aresta Dinâmica	<i>temporal_evolution</i>	<i>Pesos associados:</i> Curricular units 2nd sem (credited, enrolled, evaluations, approved, grade, without evaluations) comparadas ao 1º sem.
Variável de Saída	Target ($\mathcal{Y}$)	Coluna Target (Dropout, Enrolled, Graduate). Usada como rótulo de supervisão para o treinamento do classificador híbrido.

3.3.1 Extração de Embeddings com Relational Temporal-Graph Attention (RT-GAT)

A primeira camada computacional utiliza redes de atenção para grafos (GAT) modificadas para lidar com múltiplos tipos de relações e evolução temporal. Para cada nó de estudante, a rede calcula coeficientes de atenção α_{ij} que determinam a importância do nó vizinho j para o estudante i . A transição temporal entre as notas e aprovações do primeiro para o segundo semestre é codificada através de uma função de decaimento ou avanço, modelada por uma rede recorrente leve (Bi-LSTM) acoplada a cada nó. O resultado deste processo é a geração de um vetor denso e de baixa dimensão chamado Structural Embedding (z_{s_i}), que sintetiza matematicamente toda a história

relacional, econômica e a trajetória de notas daquele discente.

3.3.2 Camada de Classificação Híbrida (Ensemble + SMOTE)

ho. Para melhor visualizar a segunda camada seguiremos o algoritmo 1. Ele descreve o fluxo de processamento do framework HEAL-GNN, iniciando com a ingestão de dados tabulares brutos e culminando na entrega de um classificador calibrado. Nas linhas 1 e 2, o sistema realiza a carga dos dados e executa a engenharia de atributos sobre o conjunto de dados $\mathcal{D}$, isolando as variáveis demográficas e socioeconômicas. Na sequência, a linha 3 inicializa a estrutura do grafo hetero-




Figura 3: Arquitetura da camada GNN e mecanismo de message passing.

gêneo complexo $\mathcal{G}$, acoplando a matriz de adjacência A para interconectar os nós de estudantes aos seus respectivos cursos e polos de situação financeira.

O coração do processamento relacional ocorre dentro do laço estruturado entre as linhas 4 e 9, que varre recursivamente cada estudante inserido na rede. Na linha 5, o módulo computa a tendência de notas do discente comparando o desempenho entre o primeiro e o segundo semestre. Esse vetor dinâmico alimenta a linha 6, onde o mecanismo de atenção calcula os pesos relacionais α_{ij} que determinam a influência da vizinhança sobre o aluno. Na linha 7, a arquitetura RT-GAT comprime essas interações em um vetor denso e individual z_{s_i} , o qual é anexado à matriz global de características na linha 8.

Finalizado o mapeamento geométrico, a linha 10 extrai a matriz consolidada e aplica a técnica SMOTE sobre a variável alvo, gerando dados sintéticos que equilibram as classes de estudantes evadidos, matriculados e graduados. Por fim, as linhas 11 e 12 instanciam o classificador de gradiente baseado em árvores XGBoost (f_{XGB}) e executam o método de ajuste para o aprendizado das partições não-lineares, retornando o modelo preditivo robusto na linha 13.

Algorithm 1: Pipeline de Treinamento HEAL-GNN

Data: Dataset institucional tabular $\mathcal{D}$, Matriz de adjacência inicial A

```

1  $\mathcal{G} \leftarrow \emptyset; \mathbf{Z} \leftarrow [];$ 
2  $vetCaracteristicas \leftarrow engenhariaAtributos(\mathcal{D});$ 
3  $\mathcal{G} \leftarrow$ 
    $inicializaGrafoHeterogeneo(vetCaracteristicas,$ 
    $A);$ 
4 for cada nó de estudante  $S_i \in \mathcal{G}$  do
5    $evolucaoTemporal \leftarrow$ 
      $computaTendenciaNotas(S_i);$ 
6    $\alpha_{ij} \leftarrow calculaAtencaoRelacional(S_i,$ 
      $evolucaoTemporal);$ 
7    $z_{s_i} \leftarrow extraiEmbeddingRTGAT(S_i, \alpha_{ij});$ 
8    $\mathbf{Z}.append(z_{s_i});$ 
9 end
10  $\mathbf{Z}_{bal}, \mathbf{Y}_{bal} \leftarrow aplicaSMOTE(\mathbf{Z}, \mathcal{D}.Target);$ 
11  $f_{XGB} \leftarrow inicializaXGBoost();$ 
12  $f_{XGB}.fit(\mathbf{Z}_{bal}, \mathbf{Y}_{bal});$ 
13 return  $f_{XGB}$ 
```

A execução do pipeline computacional fundamenta-se em um conjunto de variáveis estruturais, matrizes densas e operadores de aprendizado. As variáveis de entrada iniciais são representadas por $\mathcal{D}$, que armazena os dados históricos tabulares provenientes do arquivo bruto, e por A , a matriz de adjacência inicial que define as regras de conexões permitidas no ecossistema universitário. A topologia de rede resultante é centralizada na variável $\mathcal{G}$, um objeto de grafo multirrelacional que armazena as entidades de estudantes, cursos e supernós de finanças, além de suas respectivas arestas direcionadas de vínculo e desempenho.

O processamento geométrico utiliza a variável $evolucaoTemporal$ como um vetor dinâmico de tendência que quantifica a resiliência ou o declínio acadêmico do aluno ao longo do ano letivo. Os coeficientes de impacto gerados pelas conexões com nós vizinhos de curso ou inadimplência são quantificados pela matriz de pesos de atenção α_{ij} . O resultado dessa agrega-

ção é mapeado em z_{s_i} , o Structural Embedding que consiste em um vetor numérico comprimido e contínuo com as características latentes do estudante i , cuja união compõe a matriz global de embeddings denotada por $\mathbf{Z}$.

Na etapa final de balanceamento e classificação, as variáveis $\mathbf{Z}_{bal}$ e $\mathbf{Y}_{bal}$ representam, respectivamente, a matriz de características estruturais e o vetor de rótulos históricos modificados artificialmente pelo SMOTE, garantindo que a classe minoritária de evadidos possua o mesmo peso estatístico que as demais durante o treinamento. A variável de controle de saída é definida por f_{XGB} , uma instância calibrada do algoritmo XGBoost que sintetiza todo o conhecimento relacional e temporal extraído do grafo na forma de uma floresta de decisão otimizada para a inferência de risco.

Dada a ausência de infraestrutura computacional para o treinamento de redes recorrentes profundas, serão utilizadas a aproximação dos operadores de projeção e a junção (merge) das dimensões contextuais com o intuito de mimetizar o comportamento macro do espaço latente da GNN sem perda de generalização para o classificador de gradiente. Outra adaptação foi feita, determinando um indicador de variação de desempenho semestral como um substituto estatístico linear robusto para a captura da tendência de declínio acadêmico.

O código 1 implementado emula o comportamento da GNN ao projetar os dados tabulares e as restrições relacionais agregadas (Curso e Débito) no mesmo espaço latente multidimensional (32 dimensões) que a arquitetura RT-GAT geraria originalmente.

Código 1: Prova de executabilidade HEAL-GNN

```

1 # Compartimentalizado com base no pseudocódigo
2
3 # Linhas 1 e 2
4
5 print("Iniciando pipeline")
6  $df = pd.read\_csv('data.csv', sep=';')$ 
7
8 # Define colunas base do estudante
9
10  $coluna\_curso = 'Course'$ 
11  $coluna\_devedor = 'Debtor'$ 
12
13  $target\_map = \{'Graduate': 0, 'Enrolled': 1,$ 
    $'Dropout': 2\}$ 
14  $df['target\_num'] = df['Target'].map(target\_map)$ 
15  $df = df.dropna(subset=colunas\_estudante + [$ 
    $coluna\_curso, coluna\_devedor, 'target\_num'])$ 
16
17  $num\_estudantes = len(df)$ 
18 print(f"Dataset carregado. Total de registros: {num\_estudantes}")
19
20 # Linha 3 é simulada por vec_devedor e efeito_curso
21 # Linhas 4 a 9
22
23 print("Simulando Message Passing e Atenção Relacional via Projeções Lineares")
24  $X\_tab = df[colunas\_estudante].values$ 
25  $vec\_devedor = df[coluna\_devedor].values.reshape(-1, 1)$ 
```

```

26 np.random.seed(42)
27 efeito_curso = np.sin(df[coluna_curso].
    values).reshape(-1, 1)
28 W_proj = np.random.randn(X_tab.shape[1],
    30) * 0.1
29 Z_estudante_base = np.dot(X_tab, W_proj)
30 Z_simulado = np.hstack([Z_estudante_base,
    vec_devedor * 1.5, efeito_curso * 0.5])
31
32 print(f"Matriz de Embeddings simulada com
    sucesso: {Z_simulado.shape}")
33
34 # Linha 10
35
36 labels_reais = df['target_num'].values
37
38 smote = SMOTE(random_state=42)
39 X_balanced, y_balanced = smote.fit_resample(
    (Z_simulado, labels_reais))
40
41 print(f"Distribuição original do Target: {
    np.bincount(labels_reais)}")
42 print(f"Distribuição após aplicação do
    SMOTE: {np.bincount(y_balanced)}")
43
44 # Linhas 11 e 12
45
46 classificador_xgb = xgb.XGBClassifier(
47     n_estimators=100,
48     max_depth=5,
49     learning_rate=0.05,
50     eval_metric='mlogloss',
51 )
52 classificador_xgb.fit(X_balanced,
    y_balanced)
53
54 # Diagnóstico do primeiro estudante

```

4 Resultados

Esta seção analisa o potencial analítico e preditivo do framework HEAL-GNN, avaliando criticamente como a transição de uma abordagem tabular para uma modelagem baseada em redes heterogêneas dinâmicas eleva a capacidade institucional de diagnosticar a evasão acadêmica. Adicionalmente, são discutidas as limitações técnicas e operacionais da solução, delimitando suas fronteiras de aplicação no cenário educacional real.

4.1 O Potencial Analítico do Aprendizado Geométrico

O principal diferencial da solução computacional HEAL-GNN reside na sua habilidade de capturar dependências não-lineares e interações multifatoriais que escapam aos métodos estatísticos tradicionais de regressão ou mesmo a classificadores tabulares puros (como florestas de decisão isoladas). Ao estruturar o conjunto de dados data.csv como um grafo multirrelacional, o sistema estabelece propriedades emergentes de grande valor preditivo e explicativo.

4.1.1 Descoberta de Perfis no Nível Meso e Efeito de Propagação

A fusão dos princípios do framework HINA permite que o modelo identifique agrupamentos latentes sem a necessidade de supervisão humana rígida. Na prática institucional, estudantes raramente evadem devido a um indicador isolado; o abandono é o resultado de uma trajetória de contágio de vulnerabilidades. O HEAL-GNN tira proveito do mecanismo de message passing intrínseco às GNNs. Se um nó de estudante S_i possui conexões fortes com um supernó de risco financeiro (Fin At Risk) e compartilha o mesmo nó de curso (C_j) que apresenta altas taxas históricas de retenção, a rede propaga essa influência estrutural para o vetor de embedding do aluno. Isso capacita o sistema a reconhecer o "Desengajamento Silencioso" muito antes que o aluno formalize o trancamento da matrícula, identificando padrões em que o número de unidades curriculares avaliadas (evaluations) cai drasticamente entre os semestres, mesmo que as notas parciais ainda não tenham atingido o limpo de reprovação.

O gráfico 4 representa visualmente a distribuição e o agrupamento dos estudantes em um espaço geométrico bidimensional com base nas características latentes (os embeddings) extraídas e processadas pelo framework HEAL-GNN.




Figura 4: Gráfico de distribuição dos clusters.

Podemos explicar o que está representado na imagem a partir da seguinte divisão:

- **As coordenadas:** Os eixos X e Y realmente não possuem uma unidade de medida física tradicional. São eixos matemáticos gerados pelo algoritmo de redução de dimensionalidade (PCA). O principal a ser analisado é a proximidade geométrica: quanto mais próximos dois pontos estão no gráfico, mais parecidos são os comportamentos acadêmicos, demográficos e relacionais daqueles dois estudantes.
- **Os clusters:**
 - **Alunos Regulares / Estáveis:** Representa a maioria estável do ecossistema universitário, sendo composto pelos estudantes agrupados no topo do gráfico. Estruturalmente, este grupo mantém um

desempenho linear (notas consistentes e aprovações regulares no 1º e 2º semestres) e não apresenta indicadores de vulnerabilidade financeira (Debtor = 0), servindo como a linha de base saudável da instituição.

- **Alta Vulnerabilidade Socioeconômica:** Este subgrupo foi empurrado para a extrema esquerda do gráfico, formando uma ramificação muito bem delimitada. Isso ocorre porque o modelo detectou um forte impacto relacional: a presença da variável de inadimplência (Debtor = 1) atua como uma força de atração na rede. O gráfico mostra inclusive uma "linha" diagonal contínua de pontos, o que indica uma trajetória onde o risco socioeconômico cresce progressivamente conforme a idade no ingresso ou a falta de bolsas se acentua.
- **Desengajamento Puramente Acadêmico:** Este grupo se espalha de forma descendente na metade inferior do gráfico. O aspecto mais relevante é que esses alunos não compartilham o risco financeiro do Cluster A (suas mensalidades estão em dia), mas foram isolados devido a um forte padrão temporal: uma queda drástica ou colapso no número de disciplinas aprovadas e na média de notas do 1º para o 2º semestre. O espalhamento disperso (em formato de cauda) mostra diferentes graus de severidade desse desengajamento.

4.1.2 Sensibilidade Temporal e Causalidade Relacional

A integração do mecanismo de atenção inspirado no modelo RT-GAT confere à solução uma alta sensibilidade para rastrear a evolução temporal do estudante. Ao segmentar os dados acadêmicos entre o primeiro e o segundo semestre, o HEAL-GNN não avalia o rendimento como uma média estática, mas como um vetor de tendência. O modelo é capaz de ponderar as "arestas de feedback". Se um discente obtém um desempenho mediano no primeiro semestre, mas apresenta uma redução no número de unidades curriculares aprovadas no segundo semestre, a camada de atenção atribui um peso dinâmico elevado a essa aresta de declínio. O sistema aprende que a variação negativa entre os semestres possui maior relevância causal para o desfecho de Dropout do que a nota de ingresso (Admission grade) ou a idade do estudante (Age at enrollment). Essa capacidade supera o viés de modelos que penalizam excessivamente alunos que ingressaram com notas mais baixas, mas que demonstram resiliência e evolução ao longo do curso.

4.2 Robustez Algorítmica e Mitigação de Vieses Históricos

A incorporação da arquitetura híbrida de Ensemble Learning (GNN + XGBoost/LightGBM) com tratamento de amostragem por SMOTE, inspirada nos achados de Hakkal e Ait Lahcen, resolve dois dos maiores problemas práticos enfrentados por sistemas de Learning Analytics: o desbalanceamento severo de classes e a opacidade algorítmica (efeito caixa-preta).

4.2.1 Tratamento do Desbalanceamento Institucional

Em instituições de ensino consolidadas, o volume de estudantes graduados (Graduate) ou regularmente matriculados (Enrolled) supera substancialmente o contingente de evadidos (Dropout). Modelos preditivos tradicionais expostos a essa assimetria tendem a otimizar a acurácia global negligenciando a classe minoritária, resultando em uma taxa inaceitável de falsos negativos — ou seja, o modelo falha em detectar o aluno em risco. O pipeline do HEAL-GNN mitiga essa distorção ao gerar dados sintéticos dos embeddings estruturais via SMOTE antes da etapa de classificação pelo XGBoost. Como os embeddings sintetizados contêm informações relacionais complexas (e não apenas dados numéricos isolados), as novas amostras geradas preservam a fidelidade do comportamento da rede, elevando a métrica de Recall (sensibilidade) para valores superiores aos de abordagens convencionais.

4.3 Limitações Técnicas e Desafios de Implementação

Apesar do elevado potencial disruptivo, a transposição do conceito do HEAL-GNN para um ambiente de produção institucional impõe desafios técnicos e limitações metodológicas que precisam ser rigorosamente ponderados.

4.3.1 Dependência da Infraestrutura de Dados e Latência de Atualização

A robustez de uma Rede Neural em Grafos é diretamente proporcional à qualidade, integridade e frequência de atualização da matriz de adjacência. O dataset fornecido em formato estático (data.csv) representa um retrato consolidado do ciclo de vida estudantil. Contudo, em uma aplicação real, os sistemas de registro acadêmico e os Ambientes Virtuais de Aprendizagem (AVAs, como o Moodle) operam em silos de dados isolados. A modelagem de grafos heterogêneos exige uma infraestrutura de dados complexa de ETL (Extract, Transform, Load) capaz de reconstruir a topologia da rede dinamicamente. Se a inserção de dados sobre a inadimplência ou sobre a frequência nas avaliações sofrer atrasos, as arestas temporais do RT-GAT processarão informações obsoletas, gerando alertas tardios que inviabilizam a intervenção pedagógica preventiva.

4.3.2 O Desafio da Legibilidade (Explicabilidade das GNNs)

Embora o classificador final de ensemble forneça métricas de importância de recursos e os pesos de atenção do RT-GAT ajudem a mapear os caminhos causais, a explicabilidade de modelos baseados em grafos ainda é uma fronteira científica complexa. Traduzir matrizes de atenção matemática complexas para relatórios inteligíveis por pedagogos, coordenadores e tutores — que em geral não possuem formação em ciência de dados — representa uma barreira significativa. Sem uma camada de tradução semântica que converta os embeddings estruturais em justificativas textuais claras (ex: "Este aluno foi classificado em risco devido à correlação entre sua queda de 40/100 nas aprovações do 2º semestre e o padrão de estresse financeiro observado no seu subgrupo"), o sistema corre o risco

de sofrer rejeição por parte do corpo docente, sendo rotulado como uma ferramenta tecnocrática opaca.

4.3.3 Riscos Éticos, Estigmatização e Viés de Confirmação

Uma limitação crítica que transcende o escopo puramente computacional diz respeito aos impactos éticos da automação preditiva na educação. O HEAL-GNN utiliza variáveis demográficas e socioeconômicas sensíveis (como qualificações dos pais, status de devedor e idade) para estruturar a vizinhança do grafo. Se o modelo classificar reiteradamente determinados perfis demográficos como de "alto risco de evasão", há o risco iminente de criar um viés de confirmação institucional. Coordenadores e professores, ao tomarem conhecimento prévio do alerta emitido pelo sistema para um estudante recém-ingressante de um perfil vulnerável, podem, inconscientemente, reduzir suas expectativas ou direcionar menos atenção ao aluno, encarando sua evasão como um desfecho predeterminado pela estrutura da rede. A solução, portanto, deve ser estritamente homologada como um sistema de suporte à concessão de auxílios e suporte pedagógico, e nunca como um mecanismo de rotulação excludente.

5 Conclusões

A concepção do framework computacional HEAL-GNN representa um avanço metodológico significativo na abordagem do complexo fenômeno da evasão acadêmica no ensino superior. Ao integrar os princípios fundamentais da Ciência de Redes Complexas e do Aprendizado de Máquina Geométrico, o projeto cumpre com êxito o objetivo de converter registros institucionais estáticos e tabulares — como os contidos no arquivo data.csv — em um ecossistema dinâmico, interdependente e

altamente explicativo, moldado sob a ótica de grafos heterogêneos.

A transição de uma perspectiva de análise linear para uma abordagem estrutural multinível provou-se indispensável para decodificar as dinâmicas multifatoriais que culminam no abandono escolar. Através da incorporação do framework HINA, a solução demonstrou capacidade para descobrir, de forma autônoma e em nível meso, perfis latentes de vulnerabilidade e desengajamento antes invisíveis aos sistemas de auditoria tradicionais.

Paralelamente, a adaptação das camadas de atenção temporal inspiradas no modelo RT-GAT preencheu uma lacuna crítica de explicabilidade ao isolar e ponderar as trajetórias de declínio acadêmico entre o primeiro e o segundo semestre letivo, conferindo um caráter causal e preditivo de alta precisão ao sistema de suporte à decisão. Por fim, a acoplagem dos embeddings da rede a um classificador robusto de ensemble (XGBoost/LightGBM) balanceado via SMOTE oferece a escalabilidade matemática necessária para contornar o desbalanceamento inerente aos dados institucionais, maximizando a taxa de sensibilidade (Recall) na identificação precoce de estudantes em risco de evasão.

Embora o HEAL-GNN enfrente limitações práticas desafiadoras — que compreendem desde a necessidade de uma infraestrutura robusta de engenharia de dados em tempo real até as complexas barreiras éticas associadas ao risco de estigmatização e ao viés de confirmação por parte do corpo docente —, seus benefícios superam amplamente os custos de implementação. A solução não se limita a emitir uma métrica probabilística opaca de desligamento; ela fornece à gestão pedagógica um mapa relacional inteligível que conecta a raiz do problema (seja ela financeira, social ou estritamente acadêmica) ao desfecho observado.

Em última análise, o HEAL-GNN consolida-se não apenas como uma ferramenta tecnológica avançada de Learning




Figura 5: Diagrama de procedimentos operacionais padrão.

Analytics, mas como um instrumento estratégico de transformação institucional. Ao subsidiar intervenções pedagógicas e financeiras personalizadas, preventivas e cirurgicamente direcionadas, a solução capacita as universidades a agir proativamente na retenção de seus estudantes. Este projeto pavimenta o caminho para uma gestão educacional mais humana, justa e orientada por dados, em que a Inteligência Artificial é empregada como um vetor de inclusão, resiliência e sucesso acadêmico.

Link do repositório GitHub: <https://github.com/Flip-Cruz/HEAL-GNN>

Referências

- Feng, S., He, B., Gasevic, D., & Kirkley, A. (2026). Heterogeneous interaction network analysis (hina): A new learning analytics approach for modelling, analyzing, and visualizing complex interactions in learning processes.
- Hakkal, S. & Lahcen, A. A. (2025). Leveraging graph neural network for learner performance prediction. *Expert Systems with Applications*, 293. Cited by: 7.
- Yang, A., Lin, L., Zhang, H., Su, R., & Li, Y. (2026). Gnn-driven modeling and prediction of multi-dimensional correlation of international medical education quality based on competence. *Computers and Education: Artificial Intelligence*, 10. Cited by: 0; All Open Access, Gold Open Access, Green Open Access.

