







HEAL-GNN: INTELIGÊNCIA EM GRAFOS PARA MITIGAÇÃO DA EVASÃO ESCOLAR




Filipe Cruz Siqueira - 2022004289

INTRODUÇÃO


"A EVASÃO NÃO ACONTECE POR UM ÚNICO MOTIVO; ELA É CONSEQUÊNCIA DE UMA CADEIA DE FATORES QUE INTERAGEM."



FLUXO DE UTILIZAÇÃO



POR QUE MODELOS TRADICIONAIS FALHAM?



CONCEPÇÃO DO HEAL-GNN

Objetivo: Transformar dados tabulares em um grafo inteligente capaz de prever e explicar a evasão.


Trabalhos relacionados:

Feng, S., He, B., Gasevic, D., & Kirkley, A. (2026). Heterogeneous interaction network analysis (HINA): A new learning analytics approach for modelling, analyzing, and visualizing complex interactions in learning processes

Hakkal, S. & Lahcen, A. A. (2025). Leveraging graph neural network for learner performance prediction. Expert Systems with Applications, 293.

Yang, A., Lin, L., Zhang, H., Su, R., & Li, Y. (2026). Gnn-driven modeling and prediction of multi-dimensional correlation of international medical education quality based on competence. Computers and Education: Artificial Intelligence,


HEAL-GNN: Topologia de Interações entre Estudantes, Cursos e Finanças



Análise de Proximidade e Distribuição dos Clusters Latentes (Meso-level)



ARQUITETURA



RESULTADOS ESPERADOS



1. CAPTURA DE RELAÇÕES NÃO-LINEARES

O modelo identifica interações complexas entre fatores socioeconômicos, acadêmicos e comportamentais.



3. ANÁLISE TEMPORAL EXPLICÁVEL

O RT-GAT rastreia a evolução acadêmica entre semestres, identificando padrões críticos de queda ou recuperação.



5. MELHOR DESEMPENHO PREDITIVO

A combinação de embeddings, SMOTE e XGBoost aumenta o Recall e reduz falsos negativos, essencial para intervenções.



2. DESCOBERTA DE PERFIS E COMUNIDADES

Permite identificar grupos de risco e perfis latentes de evasão de forma automática e não supervisionada.



4. EXPLICABILIDADE E TRANSPARÊNCIA

A atenção em arestas e nós permite entender os principais fatores que influenciam cada previsão individual.



6. SUPORTE À TOMADA DE DECISÃO

Gera alertas acionáveis e interpretações que orientam intervenções pedagógicas e políticas institucionais.

HEAL-GNN

Transformando dados em decisões para permanência estudantil

LIMITAÇÕES



TÉCNICAS

- ! Modelo depende de dados atualizados e completos.
- ! Desempenho piora com dados faltantes ou ruidosos.
- ! Exige infraestrutura computacional adequada.
- ! Manutenção e recalibração devem ser contínuas.



EXPLICABILIDADE

- ! GNNs são complexas de interpretar.
- ! Explicações dependem de métodos de atenção.
- ! Risco de interpretações incorretas por usuários.
- ! Necessita validação especializada constante.





ÉTICAS

- ! Risco de estigmatização e rotulagem de estudantes.
- ! Possíveis vieses em variáveis socioeconômicas.
- ! Uso inadequado pode reforçar desigualdades.
- ! Alerta deve ser sempre meio de acolhimento.



CONCLUSÃO

**"PREVENDO QUEM IRÁ DESISTIR, PERMITIMOS
QUE A INSTITUIÇÃO EVITE QUE ISSO ACONTEÇA."**



**OBRIGADO PELA
ATENÇÃO!**

